

IA: PANORAMA 2026 SEPT.

CAPÍTULO I

ESTRUCTURAS FÍSICAS Y PROTAGONISTAS

José María Castañé Ortega

Madrid

Septiembre 2026

IA: PANORAMA 2026 SEPT.

CAPÍTULO I

ESTRUCTURAS FÍSICAS Y PROTAGONISTAS

I.- INTRODUCCIÓN

II.- ESTRUCTURAS Y PROTAGONISTAS DEL SISTEMA IA

II.1.- PRINCIPALES ACTORES

II.2.- SUMINISTROS BÁSICOS

- De la litografía al Centro de Proceso de Datos
- La cadena oligopolística de suministro
- La litografía
- Los “chips”
- La arquitectura de chips
- Los GPUs

II.3.- CAPACIDAD DE PROCESO Y DE ALMACENAMIENTO DE DATOS: LA NUBE

- Los centros de datos
- La nube
- Las organizaciones territoriales
- La distribución mundial de centros
- Las capacidades de cálculo
- La falta de transparencia respecto a la nube
- “Hyperscalers”, los principales de la nube
- El suministro energético
- La “soberanía” en la nube
- La nube europea

II.4.- CREACIÓN DE LOS GRANDES MODELOS COMERCIALES

- Modelos de IA
- La explosión modelística (2023)
- En la República Popular la innovación no está proscrita
- Gemini (Google)
- Open GPT (OpenAI)

- Claude (Anthropic)
- Grok (xAI)
- DeepSeek

II.5.- LA PRIMERA “AGENCIA”: LA ROBÓTICA

II.6.- LA IA EN EL ESPACIO

III.- COMENTARIO: RIESGO EXISTENCIAL FÍSICO

ORIGEN DE LA INFORMACIÓN

ANEXO

I.- INTRODUCCIÓN

El progreso de la investigación y desarrollo de la inteligencia artificial (IA) está desatado y los avances y sus logros se suceden aceleradamente semana a semana y día tras día, muy aparentemente en EE UU y también, pero de forma menos explícita (para los observadores occidentales), en China.

La competencia entre los partícipes en la contienda por el poder en este sector y consecuentemente, según se piensa, en el control general de las cosas del mundo, es de especial intensidad y además es creciente.


En este contexto, la cuestión primera que se plantea en los diferentes ámbitos geopolíticos se refiere al grado de libertad de invención y aplicación de la IA que hay que permitir sin intervención regulatoria, por parte de los órganos competentes responsables de preservar el bien público.

Así el reto regulatorio, la realidad de las reglas ya vigentes, los proyectos existentes, los debates abiertos al respecto y las diferentes alineaciones de intereses e iniciativas de unos y otros y sus conflictos, configuran actualmente un panorama complejo y agitado. De éste surgirá, en un plazo no excesivamente prolongado, el tratamiento que se dé a la IA, la cual constituye, probablemente, el mecanismo de cambio más pronunciado de la condición humana desde el origen de sus tiempos.

Esta serie de tres documentos intenta exponer simplificada y ordenadamente – en la medida de lo posible – este panorama y está dedicado a las personas que (como yo hace mes y medio, cuando empecé a informarme un poco más sobre estos temas) conocen la mera existencia del fenómeno IA pero poco más, pero que por otra parte perciben su importancia y trascendencia y que desean familiarizarse algo con estos temas llamados a transformar la faz del mundo.

Tabla 1

ÁMBITOS DE LA IA



Fuente: Elaboración propia

Se abordará la descripción general que sigue, tratando el conjunto del tema de la IA como perteneciente a un sistema que se considera como único y además que tiene su vida propia. En su seno el número de interferencias y conexiones es innumerable.

Integrados en el mismo, por el lado de la demanda figuran los utilizadores de la IA: personas, corporaciones, agrupaciones, estados-naciones, autoridades territoriales, otras entidades públicas e instituciones multilaterales, sean civiles o militares.

Y por el lado de la oferta figuran, por orden de su integración vertical diferenciada, la impresión de nano-circuitos electrónicos, la fabricación de "chips", el diseño y arquitectura de conexión de estos últimos en orden


a las correspondientes especificaciones de proceso de datos, los centros de proceso y almacenamiento de información – la nube – los desarrolladores de modelos, los diseñadores y gestores de “capas” de utilización extendidas sobre los mencionados modelos. También se examinarán los protagonistas situados en la punta de lanza del progreso técnico, tanto en cuanto a capacidades fundamentales de cálculo como en lo referente a elementos básicos de alimentación de las infraestructuras (energía, frío, agua, etc...) o bien tecnologías periféricas de entrada y salida de la información de las unidades de proceso.

La visita amplia, aunque sea superficial, de este sistema ofrecerá a quienes carezcan de información, una primera idea de la magnitud de este fenómeno radical de transformación de la humanidad.

En este Capítulo I se abordan las estructuras, productos, procedimientos y protagonistas que son parte de la actividad IA, con la finalidad de sentar los fundamentos de conocimiento y familiarización que permitan una mejor percepción de la complejidad y de la dinámica del sector, de la que tratan los capítulos siguientes. Se incluye, como guía inicial visual, un esquema de los flujos y relaciones entre protagonistas principales, según su naturaleza, en el ámbito occidental-estadounidense.

Tabla 2

EL ENTRAMADO OCCIDENTAL DE LOS PRINCIPALES DE LA IA - 2026



Fuente: Elaboración propia

II.- ESTRUCTURAS Y PROTAGONISTAS DEL SISTEMA IA

II.1.- PRINCIPALES ACTORES

Si se pretendiera llegar a los estratos más profundos de los suministros de la IA, a los proveedores de los suministradores de los fabricantes de los “chips” que terminan instalados en las “nubes” de cálculo y memoria, la cadena y las ramificaciones no tendrían fin descriptivo práctico.

Limitando el panorama a lo inmediato y principal, a los actores que intervienen directamente en los procesos de elaboración directa de la IA, se puede trazar un primer perímetro que comprende unas treinta y cinco empresas o grupos principales involucrados en estas actividades a escala mundial. Como se podrá observar, la participación estadounidense es desbordante, la china es significativa y la europea incipiente.

En la Tabla 3 figuran estas empresas y grupos, que incluyen desde los omnipresentes grandes tecnogrupos de IT hasta agentes altamente especializados. Se agrupan por categorías de intervención en el sistema: los actuales desarrolladores de modelos de IA avanzados (“frontera”), los grandes tecnogrupos que generalmente controlan y gestionan capacidades de cálculo y memoria, “nubes”, los suministradores de infraestructuras, “chips” y semiconductores, los dedicados a aplicaciones especiales de la IA y los especialistas en IA aplicada a la robótica. Finalmente se incluyen los principales actores chinos y el único significativo europeo (francés).

Llama la atención la ausencia relativa de empresas de IA de los países que protagonizaron la revolución industrial y especialmente la de aquellos que habiendo perdido la segunda guerra mundial impulsaron la industrialización posbélica (1950-1980), Alemania y Japón.

Tabla 3

SELECCIÓN DE PRINCIPALES EMPRESAS DEDICADAS A LA IA

Desarrolladores de modelos fundacionales

• Open AI GPT (m. modelo)	
• Anthropic. Claude (m)	
• Google DeepMind. Gemini (m)	
• xAI (idem m.)	SpaceX
• MetaAI. Llama (m)	(código abierto)
• Safe Superintelligence (SSI)	Seguridad de la AI

Grandes tecnogrupos y sus nubes

• Microsoft	Azure (nube)
• Alphabet	Búsqueda. Android. YouTube. Gcloud (n) DeepMind
• Amazon	Líder en la nube. AWS (n). Trainium
• Meta	Facebook. Instagram. WhatsApp
• Oracle	Ex software. Invierte en la nube
• IBM	Plataforma WatsonX, gobernanza corporativa
• Salesforce	CRMs

Suministradores de infraestructuras, chips y semiconductores

• NVIDIA	GPUs, CUDA
• AMD	GPUs y aceleradores IA
• Broadcom	Semiconductores
• Corewave	Producción GPUs
• Cerebras Systems	Chips
• Arista Networks	Redes XPO en la nube
• Micron Technology	Gran productor de memorias

Aplicaciones empresariales y plataformas de datos

• Palantir	Plataforma de seguridad y defensa
• Databricks	Plataforma de inteligencia de datos
• Anysphere (cursor) adquirido por SpaceX	Herramientas de codificación
• Perplexity AI	Buscador conversacional
• Snowflake	Plataforma de datos Cortex AI en la nube

Robótica y etiquetado

• Tesla	Conducción autónoma e IA para robótica
• Waymo (Alphabet)	Conducción autónoma
• Anduril	IA aplicada a la robótica
• Scale AI	Etiquetado de datos

China

• ByteDance	TikTok / Tiantao / Donbao
• Zhipu AI	GLM-5
• DeepSeek	DeepSeek (m)
• Alibaba	Qwen / Taobao / Tmail / Alibaba Cloud
• Baidu	Ernie / Vehículos autónomos Apollo / Baidu Search / Baidu Cloud

Europa

• Mistral	Herramienta general para uso en Europa
-----------	--

Fuente: Elaboración propia

II.2.- SUMINISTROS BÁSICOS

- De la litografía al Centro de Proceso de Datos

Todo se desarrolla así (como comentario introductorio):

Una oblea de silicio (una placa circular) de 30 cms de diámetro se introduce, recubierta con una capa de resina fotosensible, en una máquina de impresión litográfica producida por ASML (Holanda) ⁽¹⁾ y queda sometida a la luz ultravioleta EUV para plasmar la imagen del patrón de una capa básica del mini-circuito electrónico de que se trate. Esa oblea sale de la mencionada máquina, que se encuentra instalada en la planta de TSMC (Taiwán) ⁽¹⁾, con los patrones ya grabados (todavía no visibles).

Una vez extraída de la máquina, es sometida, por el fundidor TSMC, a una larga sucesión de procesos: grabado químico sobre los patrones, dopaje, depósito de metales, repetición de estas operaciones decenas de veces añadiendo nuevas capas y volviendo a la máquina EUV muchísimas veces, hasta convertirse en la portadora de “chips” terminados (varios cientos de ellos en una oblea).

Los “chips”, cuadrados o rectangulares, se separan unos de otros recortando la oblea con una sierra de precisión (o laser) y se empaquetan por separado, quedando así preparado el producto que adquiere el arquitecto de “chips” NVIDIA (EE UU) o cualquier otro diseñador. El test final y el empaquetado del “chip” lo ejecutan o bien la propia TSMC o empresas colaboradoras, como ASE Technology Holding (Taiwán), con tecnología (CoWoS) de la propia TSMC.

NVIDIA recibe el paquete completo ya montado sobre su sustrato, con las conexiones listas para poder ser soldadas a una placa formando, por ejemplo, un GPU H100 (GPU, unidad de cálculo gráfico) junto con memoria adicional añadida y componentes de alimentación eléctrica y sistema de refrigeración, lo cual configura la “tarjeta” o modulo final.

Estos módulos se integran en “servidores” completos, que incluyen cada uno de ellos varios GPUs interconectados que, finalmente, se envían e instalan en los centros de datos, donde se emplazan en “racks” y se conectan finalmente a las redes. (Ver las fotografías que siguen). Y, finalmente, los “racks” se apoyan en el suelo de los centros de datos.

(1) ASML, Advanced Semiconductor Materials Lithography Holding N.V.
TSMC, Taiwan Semiconductor Manufacturing Company Limited

- La cadena oligopolística de suministro

Los arquitectos integradores-instaladores (NVIDIA, el líder de mercado, y también Samsung e Intel) demandan grandes cantidades de sus “ladrillos”, que son estos bloques de micro-circuitos, los “chips”, a los pocos fabricantes (“fundidores”) de los mismos, que existen a escala mundial (siendo, como se ha indicado, el principal el mencionado TSMC que ocupa una posición dominante en el mercado).

Pero si ya en ese penúltimo eslabón de suministro – el de los fundidores – la oferta mundial se encuentra actualmente enrarecida, en muy pocas manos (Tabla 5), todavía más concentrada y restrictiva es la oferta en el eslabón más extremo (el que está en la clave tecnológica de todo el proceso industrial o cadena de suministro), que es la construcción de la antes mencionada maquinaria de litografía de patrones de “chips” (ASML) que quedan grabados sobre las obleas de silicio (Tabla 4). La construcción de estas máquinas constituye el cuello de botella original (y principal) de todo el sistema AI.

- La litografía


Las tecnologías disponibles han influido y están condicionando actualmente, esta oferta mundial, tan restringida, de la maquinaria de litografía.

En 2024, por ejemplo, el 94% del mercado mundial de máquinas de este tipo de litografía, requeridas por la creciente miniaturización de los circuitos, fueron suministrados por el ya repetido quasi-monopolista ASML, la empresa líder en esta actividad, correspondiéndole a sus dos pequeños competidores japoneses, CANON y NIKON, en conjunto, solamente el 6% del mercado. Para dar una idea de esta preponderancia, la capacidad acumulada de lito-impresión avanzada actualmente existente en China (2025), ha sido suministrada al 99% por ASML.

Una clave histórica de la posición dominante de esta empresa fue la adquisición, en 2013, de la californiana CYMER, creada por dos físicos de la Universidad de San Diego, que la fundaron en 1986 y que ya a los dos años, utilizando gases de fluoruro de argón (FAr) y de fluoruro de kriptón (FKr), consiguieron desarrollar fuentes de luz ultravioleta profunda (DUV) mediante flujo de plasma producido por láser. Con este sistema se conseguían longitudes de onda de luz ya suficientemente

cortas para obtener la litografía con la precisión entonces deseada (entre 193 y 148 nanómetros, respectivamente). ⁽²⁾

ASML afianzó así su imbatible posición en el mercado durante poco menos de treinta años (desde la infancia del cálculo masivo y de la gran revolución de datos y la IA). Pero la empresa se tuvo que preparar para seguir adelante, sin dar respiro ni a japoneses (Canon y Nikon) ni tampoco a chinos, obsesionados por pisarle sus talones.



Haz de luz EUV durante el proceso de impresión en una máquina litográfica de ASML

(2) Nanómetro = 10^{-9} metros; mil millonésima parte de un metro

- Un átomo mide aproximadamente entre 0,1 y 0,5 nm de diámetro
- Una hebra de ADN tiene un diámetro de unos 2 nm
- Un virus típico mide entre 20 y 300 nm
- Un glóbulo rojo mide unos 7.000-8.000 nm
- Un cabello humano mide aproximadamente 80.000-100.000 nm de diámetro



Imágenes de las máquinas de litografía EUV (ultravioleta extrema) de ASML. Estas máquinas son consideradas uno de los sistemas de fabricación más complejos jamás creados, que integran más de 100.000 componentes diferentes e incluyen, cada una, una fuente de luz de estaño y una cámara de vacío más limpia que el espacio interestelar.

Para ello contaba con el cultivo tecnológico de CYMER, con la colaboración íntima y su propia inversión en CARL ZEISS SMT en Alemania (con precisiones de procesamiento óptico situadas por debajo del diámetro de un solo átomo de silicio) y por supuesto, con su propio empeño en conservar el “estatus” de quasi-monopolio que venía manteniendo.


Así consiguió el procedimiento de fuente de luz ultravioleta extrema (EUV) basado en la inclusión de un sistema generador de gotas líquidas de estaño (a razón de 50.000 de ellas por segundo, lanzadas a 241 km/hora), sistema que genera ondas mucho más cortas (13,5 nanómetros) y permite lito-impresión (de una vez, no en varias capas) con precisión muy superior.

Estas máquinas, como las últimas TWINSKAN EXE 5200. High NA EUV, de alta apertura numérica, pesan hasta 200 Tm y miden 10-13 m y se deben trocear en módulos para enviarlas por avión (varios Boeing 747 cargo) desde Ámsterdam a Taipéi.

Tabla 4

ESQUEMA DEL PROCESO EN UNA MÁQUINA DE LITOGRAFÍA EUV DE ASML

Así es, de forma simplificada, el proceso que tiene lugar dentro de una máquina EUV de ASML:



Un láser de CO₂ dispara dos veces sobre diminutas gotas de estaño en caída libre, vaporizándolas hasta formar un plasma que emite luz ultravioleta extrema 13,5 nm. Esa luz se recoge con un espejo curvo y

se dirige, rebotando en varios espejos más, hacia una máscara con el patrón del circuito.

Finalmente, un sistema óptico de espejos (no lentes, porque el EUV es absorbido por casi cualquier material) reduce y proyecta ese patrón sobre la oblea de silicio.


Todo el proceso ocurre en vacío, porque incluso el aire absorbe la luz EUV. Es justamente esta dificultad – generar, reflejar y controlar luz de una longitud de onda tan corta – lo que hace que ASML sea, hoy por hoy, la única empresa del mundo capaz de fabricar estas máquinas.

Esta nueva tecnología EUV (aplicada comercialmente desde 2019) no es sustitutiva de la clásica (DUV) sino aditiva a ella.

El procedimiento DUV ya se va difundiendo hacia la competencia (¿commodity?) sobre todo la china pero los pocos clientes de estos equipos (fabricantes de “chips”) necesitan también la precisión EUV que, de momento, solamente ASML puede ofrecer, condicionando así su comercio cautivo de los equipos DUV más tradicionales.

En el ámbito de la electrónica digital se ha producido en efecto una verdadera revolución técnica. De los clásicos transistores planos, de las placas de circuitos impresos se ha migrado al mundo de los microprocesadores, los “chips semiconductores” y las micro-memorias.


El corte transversal de un patrón nanométrico se puede esquematizar así:



Un solo chip actual puede albergar decenas de miles de millones de estas estructuras en un área de muy pocos centímetros cuadrados y sus imágenes reales solamente pueden conseguirse por medio de microscopio electrónico de barrido (SEM), pero no utilizando luz visible (longitud de onda 400 – 700 nanómetros).

La litografía óptica tradicional (DUV) que representó un gran avance sobre los transistores planos, la FinFET (con longitudes de onda de luz entre 16 nanómetros y 5 nanómetros) tiene un canal de conducción eléctrica que se denomina “aleta” y que es vertical, en silicio y la “puerta” envuelve su cabeza por tres caras, según se puede ver en el siguiente croquis de la izquierda a continuación.


En el avance hacia la miniaturización se ha desarrollado el “nanowire” o “nanosheet”, con cuatro láminas horizontales yuxtapuestas que forman el canal y en el que la punta envuelve al canal completamente, aislándolo con mayor fiabilidad. Este sistema “gate-all-around”, GAA, trabaja en dimensiones por debajo de 3 nm y requiere luz de onda más corta (EUV). Su esquema puede observarse en el lado derecho del dibujo siguiente.



La disposición ultra-precisa de las 4 láminas conductoras requiere un proceso de producción de altísima precisión – a escala atómica – repetitivo, complejo y extraordinariamente exigente, que TSMC aplica a una macro-escala industrial difícil de reproducir y que sus competidores muy improbablemente podrían conseguir a corto-medio plazo.

Tabla 5

CLIENTES DE ASML Y DE TSMC



ASML – TSMC – NVIDIA: cadena fuerte de oligopolios enfrentados

Fuente: Elaboración propia

- Los “chips”

Sin embargo ASML, en su calidad de quasi-monopolio de venta, debe hacer frente, como se ha indicado, a un oligopolio de compra, papel desempeñado por TSMC, mercado que comparte con SAMSUNG (Corea del Sur) y otros ofertantes minoritarios como INTEL (EE UU) y los fabricantes de memorias. ⁽³⁾


Los parques de maquinaria de TSMC albergan, en el eje central de su capacidad industrial, máquinas EUV de ASML (con un costo por unidad del orden de 200 M de US\$). Y además muchísimos equipos e instalaciones como, por ejemplo, sistemas de implantación de iones, unidades de grabado, sistemas de revelado, detectores microscópicos, logística interna de obleas, depósitos de materiales fotolitográficos, equipamiento de empaquetado, etc...

El proceso de producción de microprocesadores/memorias, llamados “chips” superconductores que tiene lugar en TSMC es repetitivo (hay fases que se deben reiterar entre 30 y 100 veces), complejo y duradero. La fabricación de un chip puede durar entre 3 y 4 meses desde que se inicia con la oblea y concluye con el empaquetado del chip.

(3) Aun a riesgo de insistir: esta composición de la compra a ASML de equipos de impresión por parte de todos los necesitados, se correlaciona con la distribución de proporciones de las ventas de esta última a los distintos arquitectos de sistemas de “chips” como NVIDIA (comprador principal) y otros.

De hecho TSMC es un oligopolio (junto con SAMSUNG) tanto de compra de equipos (como se ha visto frente a ASML) como de venta de “chips”, ante cualquier cliente como el arquitecto NVIDIA. Éste, a su vez, es potentísimo oligopolista de compra de chips y de venta de arquitecturas de Unidades de Procesamiento Gráfico, GPUs, a todos los grandes de la IA que tienen amplias capacidades de Centros de Datos, como AMAZON (AWS) o como BROADCOM. En medio de esta cadena de oligopolios se encuentra TSMC.

Recorrido de una oblea en la fábrica (fab)



Esa repetición se dedica, una por una, a cada capa de formación del chip (transistores, contactos, capas múltiples de interconexión, etc...).

Las etapas principales de cada ciclo son las siguientes:


- Depósito: se agrega el material de la nueva capa (silicio, óxido, metal, etc.) mediante CVD, ALD o epitaxia. Este crecimiento “epitaxial” (capas de Si y SiGe) tiene lugar en un reactor.
- Recubrimiento y exposición EUV: se prepara y expone el patrón de esa capa específica (interviene la máquina de ASML, una sola vez por capa) y en esa operación se añaden la aleta y la “puerta temporal”.
- Revelado y grabado: se elimina el material sobrante según el patrón grabado. El grabado selectivo del SiGe se realiza en la cámara de grabado seco/húmedo (“etcher”).
- Relleno con “puerta final”: lo realiza la máquina “Atomic Layer Deposition”, ALD.
- Limpieza: se eliminan residuos químicos entre cada etapa (decenas de veces).

- Implantación de iones: se "dopa" el silicio con elementos como fósforo o boro para conferirle propiedades eléctricas específicas.
- Pulido ("Chemical Mechanical Planarization") CMP: se aplanan la superficie antes de agregar la siguiente capa, ya que cualquier irregularidad se acumularía y perjudicaría a las capas posteriores.
- Metrología e inspección: se verifica que se ha fabricado dentro de tolerancias nanométricas, antes de continuar, en cada ciclo.
- Prueba eléctrica ("wafer sort"): se prueban eléctricamente todos los chips mientras aún están en la oblea, marcando cuáles funcionan efectivamente y, en su caso, cuáles no.
- Corte en dados ("dicing"): se corta la oblea dividiéndola en chips individuales.
- Empaquetado: cada chip se encapsula en su paquete final antes de integrarse en una placa (que se convierte en una placa de circuito impreso real).



A su vez los suministradores de estos muy complejos equipos de alta especialidad resultan también estratégicos, por lo que es preciso tener en cuenta orígenes geográficos como Japón y EE UU aparte de Taiwán y Holanda, el pensar en términos de seguridad de aprovisionamiento (ver Tabla 6) a escala global.

Tabla 6

PROVEEDORES DE TSMC (TAIWÁN) 2026




Fuente: Elaboración propia



La instalación más grande de TSMC es **Fab 18**, ubicada en el Southern Taiwan Science Park, en Tainan. Es el complejo de fabricación más grande de la empresa, y produce los nodos más avanzados (5nm y 3 nm actualmente, con capacidad para 2nm en desarrollo) para Apple y NVIDIA.

Un micro-circuito (“die de computo”), la esencia un GPU para un NVIDIA H100, puede medir, antes de ser empaquetado en Asia, 3,5 cm x 2,3 cm, unos 814 mm².

Junto a él van varios “chips” de memoria HBM (memoria de banda ancha), el conjunto colocado sobre una plataforma (“interposer”) de silicio de varios centímetros, y empaquetado en un “módulo GPU” (ver imagen) rectangular con 7-8 cm de lado (como una baraja de cartas).




Empaquetado avanzado de “chips”

- La arquitectura de “chips”

NVIDIA desarrolló inicialmente su negocio en el campo de los videojuegos (que actualmente resulta ser una actividad residual de la compañía) para la que creó unidades de procesamiento que funcionan masivamente (en paralelo) realizando enormes cantidades de operaciones de cálculo básicas (sumas, multiplicaciones), por ejemplo repetidamente multiplicaciones de matrices muy grandes, algo que resultó básico en la reproducción gráfica (y de ahí el nombre GPU, “Graphic Process Unit”, que se aplica, ahora sí a escala verdaderamente masiva, a algo ajeno al mundo gráfico).

Tabla 7

PROVEEDORES DE NVIDIA 2026



Fuente: Elaboración propia

Un hecho fortuito del desarrollo tecnológico de la IA hizo que este tipo de procesador GPU, en cuyo diseño NVIDIA es prácticamente monopolista, se haya convertido también en esencial para el “entrenamiento” de modelos punteros de IA.


Por su parte los CPU (unidades centrales de proceso) se aplican a resolver en serie secuencialmente conjuntos de datos más complejos.

El modelo de negocios de NVIDIA “fabless” (sin fábrica) consiste simplemente en diseñar los “chips” (miles de millones de transistores) y su lógica de procesamiento y memoria integrados y subcontratar su fabricación a una fundición externa especializada, como TSMC (ver Tabla 7).

NVIDIA produce el propio software (como CUDA) para el diseño de los chips, y adquiere directamente las memorias que son integradas por TSMC unas y por ella misma otras.

El sistema alternativo al “fabless” de NVIDIA es el IDM, de integrar también la fabricación, que practican los participantes minoritarios en el mercado de “chips”: SAMSUNG e INTEL.


GPUs DE NVIDIA




Módulo GPU. Unidad típica aplicada por NVIDIA. H100 NVL

NVIDIA Data-Center GPUs Specifications				
VideoCardz.com	NVIDIA H100	NVIDIA A100	NVIDIA Tesla V100	NVIDIA Tesla P100
Picture				
GPU	GH100	GA100	GV100	GP100
Transistors	80B	54.2B	21.1B	15.3B
Die Size	814 mm ²	828 mm ²	815 mm ²	610 mm ²
Architecture	Hopper	Ampere	Volta	Pascal
Fabrication Node	TSMC N4	TSMC N7	12nm FFN	16nm FinFET+
GPU Clusters	132/114*	108	80	56
CUDA Cores	16896/14592*	6912	5120	3584
L2 Cache	50MB	40MB	6MB	4MB
Tensor Cores	528/456*	432	320	-
Memory Bus	5120-bit	5120-bit	4096-bit	4096-bit
Memory Size	80 GB HBM3/HBM2e*	40/80GB HBM2e	16/32 HBM2	16GB HBM2
TDP	700W/350W*	250W/300W/400W	250W/300W/450W	250W/300W
Interface	SXM5/*PCIe Gen5	SXM4/PCIe Gen4	SXM2/PCIe Gen3	SXM/PCIe Gen3
Launch Year	2022	2020	2017	2016

Ejemplos de GPUs de NVIDIA



Tarjeta ya montada de NVIDIA con 8 GPUs



Tarjeta NVIDIA H100 Hopper dispuesta a entrar en acción.

- Los GPUs

El 89% del negocio de NVIDIA se produce en el dominio de la construcción de unidades de procesamiento GPUs (en los que se integran los “chips”) donde opera con márgenes brutos altísimos (del orden del 73-75%) y en el que captura el valor de la capa exclusivamente de diseño de la capacidad de cálculo al servicio de la IA de alto nivel tecnológico. Esto le permite generar fondos que suponen un potencial de intervenir decisivamente en la financiación del conjunto del sector de procesamiento de datos IA.

Los centros de cálculo de las nubes AWS (Amazon) y AZURE (Microsoft) están en manos de NVIDIA para obtener los GPUs que les permiten entrenar modelos de IA de vanguardia.

Sin embargo GOOGLE CLOUD ha podido escapar a esa dependencia a través de un nuevo instrumento, el TPU (la unidad de procesamiento tensorial) lanzado en 2016, que realiza multiplicaciones masivas de muy grandes matrices (de hasta 256 filas x 256 columnas), típicas de las redes neuronales, con las que, mediante una arquitectura de chips de “bombeo” de datos (alimentación “sistólica”), perfecciona el entrenamiento de sus propios modelos avanzados de IA (Gemini).

Estos módulos se aplican a una “tarjeta” (H100) de 26,7 cm x 11,2 cm, que pesa del orden de 1,4 kg, que es la que se integra en el servidor.



SERVIDOR DELL TODAVÍA NO INSTALADO EN EL RACK

También en la vertiente física los servidores, por ejemplo el NVIDIA PGX H100, se perciben como una caja metálica rectangular de 35,3 cm alto, 44,7 cm ancho y 90,0 cm de profundidad, pesan entre 130 y 135 kg y llevan 8 GPUs NVIDIA H100 (el de la imagen es un servidor Dell PowerEdge).

Entre 4 y 8 servidores se apilan en un “rack” (NVIDIA DEX/6B 200 NVL 72) de 2,1 m de altura, 60 cm de anchura y 1-1,2 m de profundidad, instalado en un centro de datos. Y los pasillos de los centros están formados por muchos “racks” alineados uno al lado de otro.



SERVIDOR DELL YA INSTALADO EN EL “RACK”



BATERÍA DE “RACKS” EN CENTRO DE DATOS

II.3.- CAPACIDAD DE PROCESO Y DE ALMACENAMIENTO DE DATOS: LA NUBE

- Los centros de datos

Los centros de datos, dotados de los mencionados instrumentos de cálculo (los GPUs, los CPUs y los TPUs), bien agrupados y fuertemente alimentados por electricidad, frío y agua, precisan del concurso e incorporación de modelos (o algoritmos) que dirigen el procesamiento de los datos.

Estos centros pueden ocupar edificios de entre 100,000 y 300.000 m² de 4-6 m de altura, con pasillos internos (de una anchura entre 1,2 y 1,8 metros) de longitud entre 30 y 50 m, que albergan cientos de “racks” uno al lado de otro.

- La nube


La nube, el conjunto articulado de centros de datos e infraestructuras donde se produce esta actividad de cálculo, es elemento central de la IA y constituye actualmente un negocio con un ritmo de propagación extraordinario. Los agentes principales actores de la nube son los grandes grupos de IT e IA y la terna de líderes actual está formada (por orden de tamaño en esta actividad) por AWS (Amazon), AZURE (Microsoft) y GOOGLE CLOUD (Alphabet), entre los cuales los dos primeros carecen de modelos avanzados propios (modelos “frontera”) y el tercero sí los posee (constituyendo Google, actualmente, el gran grupo integrado de IA más completo del sector).

- Las organizaciones territoriales

Estos centros de datos están organizados por parte de estas empresas (las mencionadas y otras de gran alcance técnico y económico como, entre otras, por META y ORACLE), en estructuras territoriales.

Los centros de datos tienen que estar localizados cerca de las concentraciones geográficas de usuarios (por causa de la latencia requerida, el tiempo de transmisión de la información, por más que ésta se pueda mover a la velocidad de la luz). Esto implica que, en vez de acercar los centros a la generación de electricidad, sea preciso actuar a la inversa, aproximando la producción de esta última a los mencionados centros de procesamiento de la información, cercanos a los núcleos urbanos, de uso intensivo de IA.

Los grupos gestores de infraestructuras en la nube establecen regiones, las cuales se subdividen en “zonas de disponibilidad” dentro de las cuales varios centros de datos (en número de 3 o 4) comparten el suministro eléctrico, las estructuras de refrigeración y las redes de comunicación.



IMÁGENES EXTERNA E INTERNA DE CENTROS DE DATOS

- La distribución mundial de centros

Así, en regiones, zonas y centros controlados por las empresas de la nube, se distribuye la capacidad IA (Tabla 8) del mundo:

Tabla 8

NÚMERO TOTAL DE CENTROS DE DATOS EN EL MUNDO
(2025)

Estados Unidos	5.427
China	449
Europa	3.373
Rusia	251
Australia	314
Japón	222
Corea del Sur	147
India y resto de Asia	~1.600
Sudamérica	654
África	?
Total mundo	~12.000

Casi tres cuartas partes
del número de centros de
datos está en EE UU y
Europa

- Las capacidades de cálculo

En lo relacionado con la capacidad y la efectiva realización de cálculo se plantearon, desde el principio de estas actividades, inevitablemente, las cuestiones relacionadas con las unidades y referencias de medida de las mismas.

Desde el punto de vista conceptual se consideró la unidad esencial de computación, el FLOPS (operación en cifra de “punto flotante” – p.e.: $X \bullet 10^n$, sea ésta una suma, resta, multiplicación o división) por segundo, unidad de velocidad de cálculo y, si se trata de volúmenes de cálculo realizados entonces la unidad no sería el FLOPS sino el FLOPs (con “s” minúscula), correspondiendo al número total de operaciones básicas ejecutado.

Sin embargo esta unidad ha resultado poco práctica para establecer comparaciones de volúmenes de actividad de los centros de datos o de sus conjuntos, sobre todo porque los actores apuestan, en general, por llevar su juego de despiadada competencia bajo el signo de la falta de transparencia generalizada. Unos prefieren no revelar el número de centros con el que cuentan y otros prefieren no informar sobre su capacidad de cálculo instalada, ni siquiera a través del sistema más

común (para dar cifras comparables) consistente en el “chip equivalente” – siendo comúnmente utilizado como referencia el H-100 de NVIDIA.

Así, por ejemplo, Google no informa sobre el volumen de chips “H-100 equivalentes” que tienen sus centros de cálculo, mientras que AWS no publica ni el número de centros de datos que tiene, ni el conjunto de su consumo eléctrico anual.

- La falta de transparencia respecto a la nube

Este estado de relativa carencia de información en un sector ya de grandísimo tamaño y en fase de crecimiento explosivo (doblando su tamaño económico cada 6, 8 meses), se correlaciona con el limitado nivel de regulación de la IA a nivel federal. De alguna forma, la facturación de la nube y consumo eléctrico total dan idea adicional de la capacidad de los grupos. Se incluye, como ejemplo, el caso de Google (Tabla 9).

Tabla 9

TIPOS DE DATOS DISPONIBLES SOBRE LA NUBE (2024, 2025). CASO DE GOOGLE

GOOGLE CLOUD			2024	2025
CÁLCULO	CAPACIDAD	Chips instalados equiv. H-100 Nvidia	La mayor de todas ⁽⁴⁾	La mayor de todas ⁽⁴⁾
	CAPACIDAD / ACTIVIDAD	FLOPs ⁽⁵⁾	?	?
	ACTIVIDAD	Facturación 10 ⁶ US\$	nd.	58.710
		Consumo de electricidad GWh	30,8	42,00

Fuente: Elaboración propia

El FLOPs, sin embargo, sí es utilizado en las estimaciones de volumen de cálculo necesario para entrenar (y poner a punto) modelos avanzados “frontera”, en las negociaciones entre innovadores y gestores de las nubes.

(4) Ni siquiera se comunica la capacidad instalada de chips en su parque de cálculo! Además Google no es el “hyuper” menos transparente de la nube.

(5) Cantidad total de cálculo realizado, es decir número de operaciones simples (suma, resta, multiplicación, división) en formato de cifras en coma flotante, es decir $X \cdot 10^n$ (la necesaria para entrenar un modelo de IA avanzado es de 10^{26}).

Así, por ejemplo, la propia definición de lo que es un modelo “frontera” se establece también el número de FLOPs necesarios, concretamente en 10^{26} .

- “Hyperscalers”, los principales de la nube

Con estas limitaciones y unidades de medida, se indica a continuación un contorno de los tamaños (ver Tabla 10) de las nubes de los tres grupos principales.

Sin embargo sí han fluido hacia la información publicada datos combinados de participación en la nube, de enteros grupos de “hyperscalers”.

Así, por ejemplo, el conjunto de los tres principales anteriores (Amazon, Google y Microsoft) más Meta y Oracle significa el 71% del cómputo mundial total en 2025 (porcentaje que en 2024 fue del 63% [Epoch]) y la capacidad total de cómputo de los “hyperscalers” alcanzó 49 GW en 2025, de los que los mismos res primeros representan el 80% del total, es decir unos 39 GW (Wells Fargo, Yahoo Finance).

El mayor centro de datos del mundo tiene una capacidad de $1,1 \times 10^6$ H100e (unidades equivalentes del chip de NVIDIA).

- El suministro energético

Otro aspecto esencial del funcionamiento de la nube es el suministro energético. La vida expansiva del sector IA está rodeada (y amenazada o presionada) por cuellos de botella, situación que se examina más detenidamente en este informe más adelante y uno de los principales es el masivo consumo de electricidad por los centros de cálculo.

Para hacer frente a esta necesidad, los gestores deben prever soluciones a corto, medio y largo plazo. Desde las urgencias de las inmediateces hasta grandes inversiones para garantizar un futuro tan expansivo.

En este campo la falta de transparencia generalizada también aparece, con un protagonismo oscurantista encabezado por AWS, quienes no hacen la menor referencia a su consumo eléctrico (aunque se le supone, en su calidad de líderes del sector, con una participación presumible en el mercado de la nube del 30%).

Tabla 10

CAPACIDADES Y NIVELES DE ACTIVIDAD EN LAS NUBES DE LOS TRES PRINCIPALES
“HYPERSCALERS” (2025)

“HYPERSCALERS”	ESTRUCTURA GEOGRÁFICA (número)			CONSUMO ELÉCTRICO NUBE (TWh)			NEGOCIO 2025	
	Regiones	Zonas de disponibilidad	Centros de datos	2024	2025	Δ	Facturación 2025	Δ
AWS (Amazon)	33	115	¿?	¿?	¿?	¿?	128.700 x 10 ⁶ US\$	20%
GOOGLE CLOUD	43	130	¿?	30,8	42,0	37%	58.710 x 10 ⁶ US\$	35,8%
AZURE (Microsoft)	70	¿?	400	30,0	37,0	24%	75.000 x 10 ⁶ US\$	34%

Fuente: Elaboración propia

Las fuentes de suministro energético para estos fines deben ser de fluido ininterrumpido 24/7. Con costes marginales de 0,02÷0,03 US\$ por KWh, la energía nuclear es la más adecuada en principio (la hidroeléctrica, la solar y la eólica son más económicas cuando funcionan, pero los GPUs funcionan en continuo 24 horas al día).

El sector nube promueve acuerdos, soluciones e inversiones-adquisiciones en el sector nuclear, pero la solución más adecuada, de cara al futuro, son los reactores nucleares modulares pequeños, en cuyo desarrollo están invirtiendo los grupos principales: Microsoft a través de la "newco" Helion Energy, Google respaldando a Kairos Power y Amazon adquiriendo centros ya alimentados por estas pequeñas plantas.

Mientras estos suministros se organizan, se recurre, como solución puente, a las plantas de gas natural de ciclo combinado en las que están invirtiendo, en urgencia, las eléctricas tradicionales (como NextEra, Constellation y Vistra).

Una idea de la importancia del consumo total combinado de energía de la nube podría ser, según informaciones varias, de este orden (duplicación en cuatro años).

Tabla 11

CONSUMOS TOTALES DE ENERGÍA

	EE UU	China
2022	460 TWh	Nd.
2026	1.000 TWh	Nd.
2030	Nd.	400 TWh

Fuente: Elaboración propia

- La “soberanía” en la nube

Finalmente, otra cuestión básica, que influye en la configuración de la nube a escala mundial, es el concepto de “soberanía”, que conoce un desarrollo específico en Europa muy revelador de la íntima relación entre la potencia efectiva de cálculo y de memoria por un lado y el poder político por otro.

La esencia de este concepto consiste en la distinción entre residencia o depósito (“residency”) de los datos y el control o disposición de los mismos.

La cuestión es relevante en general y muy especialmente, en la actualidad, en lo que afecta al funcionamiento internacional de las nubes de IA (y a los datos en general) y las relaciones entre EE UU y Europa.

En efecto, por una parte, EE UU aprobó la CLOUD Act (¡qué casualidad su nombre!), “Clarifying Lawful Overseas Use of Data Act” el 23 de marzo de 2018 (y ese día entró en vigor), según la cual los proveedores de servicios (como Microsoft, Google, etc...) deben entregar cualesquiera datos solicitados por orden judicial estadounidense, independientemente de donde estén almacenados físicamente (dentro o fuera del país).

Por otra parte el reglamento (UE) 2023/2854 (UE Data Act). Capítulo VII, aplicable desde septiembre de 2025, establece en el derecho positivo europeo la obligación de bloquear activamente accesos extraterritoriales no autorizados (en respuesta directa al Cloud Act estadounidense).

Este es un conflicto jurídico-político transatlántico servido en bandeja de plata y sin solución al día de hoy.

En cualquier caso, la confidencialidad de los datos almacenados nacionales, empresariales y administrativos, como bien intrínseco a preservar, entra en conflicto directo, como se puede ver, en el complejo uso de la información y en la práctica de la IA en la nube.

El asunto de la soberanía IA europea en relación con EE UU (y cualquier otra potencia IA) es una manifestación viva y actual de un fenómeno más general que se refiere a la evolución tecnológica y geopolítica del mundo: el poder creciente de la información como elemento integrante de las balanzas de poder en las relaciones internacionales.

La composición de la propia riqueza de las naciones está mutando a medida que la capacidad de procesar datos, de acumularlos y de utilizarlos en actividades pacíficas o bélicas se va concentrando en focos geográficos. Este desigual deslizamiento del poder, reforzado por el proyecto técnico de la IA se medirá pronto en términos de control: quien domine la información tendrá un instrumento formidable para someter a otro a sus propios intereses y decisiones. Eficacia soberana es sinónimo de control incondicional.

A los grandes estadounidenses les preocupa el régimen de multas practicado por la UE, pero menos de lo que Cloud Act preocupa a los usuarios privados y públicos europeos.

- La nube europea

El proyecto europeo GAIA-X ha tenido un arranque lento y en su fase actual es solamente un sistema de coordinación, definición de estándares de interoperabilidad y de certificación de iniciativas europeas en la nube capaces, entre otras características, de garantizar soberanía europea.

En el ámbito europeo se han desarrollado, entre otros, diversos programas de nube como estos:

- En Francia: OVHcloud, Scaleway
- En Alemania: STACKIT, Hetzner, Open Telekom Cloud
- En Suiza: Exoscale
- En Finlandia: UpCloud
- En Polonia: CloudFerro

Y se han promovido proyectos federados como Virtuora.

Pero los tres grandes estadounidenses todavía tienen un gran peso (del $\cong 75\%$) en el mercado de la nube europeo, a pesar de los riesgos que afectan a la soberanía de la información.

Finalmente en el conflicto europeo-estadounidense, se ha abierto una vía no de acuerdo sino de evitación, en parte, del problema, mediante la creación en 2023 del proyecto MISTRAL (por exalumnos de la École Polytechnique y ex investigadores de Google Deep Mind y de Meta AI) dedicado al desarrollo de modelos “abiertos” (accesibles sin contraprestación directa).

Microsoft cerró, en efecto, en julio de 2026, un acuerdo con Mistral para financiar capacidad de cálculo en Europa y sus clientes podrán utilizarlos en Francia, escapando a la “lunga manus” de la Cloud Act.

Finalmente la AI Act de la UE crea la posibilidad hasta ahora virtual (y quizá real en algún momento futuro), de que un desarrollador de modelos (como Anthropic) acosado por el gobierno de su propio país (como el del Presidente Trump) decida entrenar sus creaciones en suelo europeo de manera protegida respecto a la capacidad de ejecución extra-territorial estadounidense.

II.4.- CREACIÓN DE LOS GRANDES MODELOS COMERCIALES

- Modelos de IA

Un modelo de inteligencia artificial es un sistema de cálculo, o de transformación de datos, que ha sido entrenado para percibir y reconocer patrones y aplicar ese conocimiento a la realización de tareas específicas, como clasificar información, generar contenidos o proponer o tomar decisiones, sin intervención humana.

Un modelo es un útil que tiene capacidad de aprender a partir de ejemplos. Se le ofrecen muchísimos datos y mediante reglas o algoritmos matemáticos ajusta su capacidad de transformar la información (p.e. las preguntas) en respuestas correctas ante planteamientos que nunca había percibido antes, porque ha aprendido él solo – el modelo en su propio entrenamiento – a generalizar.

Los elementos principales de los que consta un modelo IA, como los que se comentan más adelante, son:

- La estructura matemática general del modelo (llamada a menudo arquitectura), p.e. redes neuronales, árboles de decisión, resortes vectoriales, etc...
- Los “parámetros” (pesos y sesgos), números que intervienen en las operaciones (FLOPs) que conducen al resultado, que inicialmente – en el entrenamiento – son introducidos como aleatorios y que se van ajustando a lo largo del proceso, hasta llegar a una situación definitiva (que se corresponde con una capacidad de generalizar aceptable). El número de estos parámetros puede llegar al billón y más.
- Los “datos de entrenamiento” (texto, imágenes, audio, tablas, etc...), una avalancha masiva de información.
- El nudo esencial: el “algoritmo de aprendizaje”, que es el método matemático (como el basado en el “descenso de gradiente”), que engendra la modificación permanente y el perfeccionamiento de los parámetros, hasta llevarlos a su estructura final.

En el mundo de la IA, una de las grandes ramas, a la que pertenecen los modelos actualmente activos en el mercado es la de “aprendizaje automático” (en inglés “machine learning”), y dentro de esta categoría la que realmente concierne a lo que sigue, son los modelos de “aprendizaje

profundo” que utilizan, en cualquier caso, redes neuronales con muchas capas, lo que les permite aprender representaciones complejas.

Estos modelos requieren enormes cantidades de datos para su entrenamiento de aprendizaje y gran capacidad de cálculo (GPUs o TPUs) para detectar qué características de los datos son más relevantes.

En el aprendizaje profundo de los grandes modelos basados en lenguaje los parámetros son piezas esenciales. El número de parámetros suele utilizarse como una medida de la ambición y la capacidad del modelo. Su progresión, en la carrera de la modelística es incesante. Por ejemplo:

Modelo	Parámetros aproximados
GPT-2 (Open AI)	1,5 mil millones
GPT-3 (Open AI)	175 mil millones
Modelos actuales grandes	Varios cientos de miles de millones a billones

El método más difundido de modificación progresiva – ajuste – de parámetros es el antes mencionado de “descenso de gradiente”.

El “gradiente” en este caso es un vector (una flecha con un punto de partida, una dirección y una longitud) que indica la dirección (en un plano) en la que una función (algo que se mide) crece más fuertemente (en la tercera dimensión, con más pendiente hacia arriba) y su magnitud indica cuán empinada es esa pendiente.

Aquí todo se mueve en el sentido opuesto al gradiente que, como se ha dicho, es de aumento. Lo que se pretende es la disminución – y por eso se llama “descenso de gradiente”. El gradiente en aumento de un parámetro indica que su contribución aparta el resultado del correcto y el gradiente en descenso máximo indica que el ajuste del parámetro evoluciona en el sentido correcto para ayudar a que el resultado (el contenido de la salida) sea correcto.

Por ello una forma de proceder con el último resultado es ir hacia atrás en las capas de cálculo, de capa en capa, parámetro por parámetro, hasta llegar al último que fue el primero y sacar conclusiones – la propia máquina – sobre lo que hay que ajustar en el parámetro perturbador (“retro-propagación”).

Investigadores de Google, en 2017 (paper “Attention is all you need”) revolucionó el dominio del procesamiento de lenguaje natural, basado en el “transformador” y en el concepto de “auto-atención”, que permite que el modelo evalúe cada palabra estableciendo cuán relevantes son todas

las restantes para entender el contexto preciso de la evaluada (p.e. un “banco” puede ser un gran conjunto de peces o un objeto para sentarse).

Lo primero que hace el modelo es “fraccionar” todas las palabras dividiéndolas en “tokens” (representados por vectores en el tratamiento numérico), trozos esenciales de palabras, pues el ejercicio del modelo consiste en predecir correctamente el “token” siguiente que corresponde a continuación de todo lo anterior (tokens articulados en palabras) que figura en la salida.

Entre los “transformadores” existen los codificadores – decodificadores, los solamente codificadores y los solamente decodificadores. Son estos últimos los utilizados en estos modelos generativos, por su simplicidad de aplicación y por otras características (como por ejemplo su capacidad para relacionar palabras muy separadas en el texto).

El proceso de “retro-propagación” se realiza millones de veces, corrigiéndose, parámetro por parámetro, hasta llegar a la perfecta o casi perfecta generalización: ¡respuesta correcta!

Es fácil comprender que estas campañas masivas de entrenamiento para poder establecer la validez de estos modelos requieren muy voluminosas inversiones en I+D por parte de los desarrolladores de los mismos que consisten principalmente en enormes cantidades de cálculo facturadas por los “hyperscalers” a través de sus centros de datos.

Así, algunos GPT han implicado cantidades de inversión del orden de 100 M de US\$, y volúmenes del mismo tenor han sido gastados por los otros promotores de modelos “frontera” (Anthropic y xAI). Para Google el tema ha implicado macrofacturaciones intragrupo entre GoogleCloud y Google DeepMind.

Ahora bien, en este campo, una revolución radical se ha producido en China, cuando DeepSeek ha desarrollado recientemente modelos abiertos con prestaciones cercanas a los cerrados recién mencionados, invirtiendo en su entrenamiento (más otros gastos de puesta a punto) entre 5,6 y 6,0 millones de dólares por modelo.

Esto lo ha conseguido esta empresa china recurriendo a útiles matemáticos pre-existentes (post segunda guerra mundial) relacionados con las “matrices doblemente estocásticas”, que son aquellas que cumplen las dos condiciones siguientes:

- (a) no contener números negativos
- (b) todas las filas suman 1 y todas las columnas suman 1

con lo que tanto cada fila como cada columna pueden expresar distribuciones de probabilidad.

La aplicación sucesiva del algoritmo de Sinkhorn-Knopp y del teorema de Birkhoff-Von Neumann, llevó a un control de la estabilidad de los resultados de cálculo (que no se dispararon saliéndose de límites de control) con lo que el número de repeticiones necesarias disminuyó drásticamente y con ello el tiempo de entrenamiento y de la facturación de la nube, y la inversión en I+D y así el riesgo asociado al proyecto de desarrollo del nuevo modelo.

Esta revolución pone en cuestión la tecno-economía de los modelos “frontera” de Silicon Valley. Pero los mercados financieros, que vibraron en su momento, ahora, en vísperas de los grandes lanzamientos bursátiles de Open AI y de Anthropic, han parecido padecer alguna forma suave de amnesia. Esto fue así hasta el 12 y 13 de septiembre 2026, en que han decidido, presentándolo hábilmente de otra forma (miedo a un futuro que de hecho no temen), aplazar su impaciencia financiera y sus proyectos bursátiles.

- La explosión modelística (2023)

Pero volviendo a la historia, en 2018 se desencadenó una verdadera revolución: la empresa Open AI, fundada por Sam Altman, Elon Musk y otros ingenieros de sistemas, lanzaron el modelo fundacional (propietario, que pone sus servicios a disposición de la clientela, bajo remuneración) GPT1. Así, esta empresa difundió la primera aplicación de la IA puesta al alcance general del público con carácter universal.

Por una parte ello significó el inicio de una nueva era, porque tangibilizó lo que la IA podía aportar a escala del gran público y por otra parte provocó un efecto-demostración en el sector de la tecnología IA, en el que jugadores decisivos se activaron, a la vista de esta innovación, con la finalidad de emularla y dispuestos a superarla.

Algún tiempo después otros tres núcleos de creación tecnológica estaban en marcha para desarrollar sus respectivos modelos fundacionales y en 2023 los tres lanzaron sus capacidades de IA conversacional al mercado:

Google, que llevaba más tiempo trabajando en ello y dos iniciativas nuevas, Anthropic, que había surgido de un equipo de Open AI que se había separado de esta empresa.

Por su parte xAI fue efectivamente la respuesta de Elon Musk a Open AI. En su enfrentamiento con Sam Altman (y su consecuente dimisión del

Consejo de Administración de Open AI a la que siguió el histórico pleito que el promotor de Tesla habría de perder).

Estas dos últimas empresas lanzaron respectivamente el tercero y cuarto de los modelos fundacionales que se habían introducido en el mercado bajo los nombres, respectivamente, de “Claude” y “Grok”.

Desde un punto de vista físico un modelo “frontera” se compone de los siguientes elementos:

El elemento clave es un archivo con miles de millones (o billones) de “parámetros” numéricos (los “pesos”) resultado del entrenamiento del modelo (cientos de gigabytes o varios terabytes) almacenados en sistemas de alta velocidad integrados por arreglos de discos SSD NV Me.

Estos últimos están montados en una o varias unidades de “racks” muy parecidos a los que contienen GPUs, pero llenos de soportes de discos y discos (una sola bandeja puede pesar entre 20 y 40 kg).

Estos modelos pueden llegar a ocupar varios “racks” completos y el conjunto pesar varios cientos de kg o incluso una tonelada o más.

Tabla 12

EXPLOSIÓN DE LOS MODELOS DE IA (2018-2026)

GENERADORES DE MODELOS	2010	2011	2012	2013	2014	2015	2016	2017	2018	2019	2020	2021	2022	2023	2024	2025	2026
GOOGLE Gemini	Creación de DeepMind (Londres)	→	→	→	Google compra DeepMind	→	→	→	→	→	→	→	→	→	Febrero BARD Fusión interna Gemini	→	Gemini 3.1 PRO
Open AI						Creación de Open AI	→	→	GPT1	→	→	→	Agosto GPT 3.5	→	→	→	GPT 5.6 SQL
xAI Grok									Musk fuera Consejo Adm. Open AI	→	→	→	→	9 marzo creación xAI Nov. 1er modelo	→	Adq. de Twitter	Feb: SpaceX adq. xAI
Anthropic Claude												Creación de Anthropic	→	Claude	→	→	Claude Opus 4.8
DeepSeek												Fondo High Flyer compra 10.000 GPUs a Nvidia	→	Mayo Creación DeepSeek	→	Enero: R1	

Fuente: Elaboración propia

- En la República Popular la innovación no está proscrita

Paralelamente en China un empresario con privilegiada visión de futuro – Liang Wenfeng – había adquirido en 2021 varias decenas de miles de GPUs a NVIDIA, anticipando por una parte que EE UU acabaría por imponer pronto restricciones a la exportación de estos instrumentos de cálculo, por otra en preparación de las necesidades de entrenamiento de modelos que pudiera después desarrollar y por último, con el propósito de lanzarlos al mercado de forma no propietaria sino abierta.

Y consiguió todos estos objetivos al haber fundado, en 2023, DeepSeek y presentar el 27 de enero de 2025 su instrumento R1. Su aparición en el mercado provocó la caída generalizada de las cotizaciones bursátiles de las empresas estadounidenses de IT involucradas en la actividad IA.

Wenfeng ya se había distinguido por aplicar el concepto “hacer mucho con poco”. Había desarrollado el modelo anterior V3 con una inversión de 6 millones de US\$ (frente a los 100 millones de GPT4) y lo había conseguido en dos meses. El R1 se entrenó con solamente 2048 GPUs de NVIDIA H800 (versión reducida para China, por efecto de las restricciones estadounidenses) y había costado 5,6 millones de US\$. Estos hechos revolucionarios ya se comentaron, con más detalle, en el punto anterior.

Los últimos modelos de estas cinco líneas de esfuerzo, cuatro fundacionales-propietarias estadounidenses y una abierta china, constituyen el presente frente avanzado de la IA a nivel comercial planetario y son la culminación actual perfectible de la aplicación de las grandes técnicas de la IA generativa basada en lenguajes.

Todos estos modelos comparten el mismo esquema o esqueleto de diseño antes comentado “transformador solamente decodificador”.

- Gemini (Google)

El actual modelo de Google, Gemini 3.1 Pro (de febrero 2026) por una parte incluye una fórmula que denominan “sparse” de “mezcla de

expertos” ⁽⁶⁾ y por otra no procesa primero textos y luego les “pega” imágenes sino que, de inicio, procesa datos multimodales de forma integrada. Añade además una verificación de “cadenas de pensamiento” que elaboran un grafo de control compuesto por nodos, que son premisas lógicas, mediante el que se pretende detectar inconsistencias. Google mantiene secreto absoluto sobre el número de “parámetros” de este modelo.

- Open GPT (Open AI)

Open AI, al parecer le añadió, a partir de GPT-4, un dispositivo adicional, del tipo también “mezcla de expertos”.

GPT-5 no es un modelo singular sino un distribuidor (en anglicismo un “enrutador”) a una serie de modelos seleccionables según la complicación de la formulación de entrada, es decir que calibra cuánto esfuerzo requiere cada pregunta, o parte de pregunta.

En cualquier caso Open AI guarda también celosamente en secreto la cifra de parámetros de sus GPT.

- Claude (Anthropic)

El modelo de Anthropic, empresa creada en 2021 por los hermanos Amodei y algunos otros técnicos de Open AI, Claude Sonnet 5 (de junio 2026), con arquitectura como los demás, consistente “transformador”, incorpora un filtro general de entrenamiento denominado “Constitutional AI”, con la finalidad de auto-regularse y servir fines aceptables desde la perspectiva ética.

Es un modelo el “Claude” entrenado desde cero, no ajustado sobre algún modelo abierto y por lo tanto disponible de terceros. Es un modelo con prolongación agéntica (no se limita a su inteligencia y a sus conclusiones, propuestas y decisiones sino que se dirige hacia la ejecución). Por encima de este modelo está, en su propia gama, Opus 4.8.

- Grok (xAI)

El modelo 4.5 Grok de xAI, empresa fundada por Elon Musk, se construyó también bajo esquema de “mezcla de expertos”, con 1.5

(6) Lo que permite movilizar de forma selectiva solamente, en cada caso, una parte especializada (“experta”) del enorme conjunto de los parámetros (los cuales anticipan cuál es el “token” siguiente que aparece en la conversación de salida), abaratando las operaciones de salida (“inferencias”).

billones de parámetros. El entrenamiento se realizó con decenas de miles de GPUs NVIDIA GB300.

Grok 5 todavía está en entrenamiento, en el Colossus 2 en Memphis, con cientos (no decenas) de miles de GPUs NVIDIA de última generación (Blackwell y Blackwell Ultra) que xAI califica como el mayor supercomputador de entrenamiento del mundo.

Lo que parece es que estos modelos estadounidenses no se diferencian tanto en su arquitectura (todos recurren a “mezcla de expertos” para la inferencia) como en lo relacionado con la escala y ahí la cifra de parámetros total y sobre todo la de parámetros “activos” que es fundamental.

El secretismo de casi todos y los alardes de capacidad potencial de Musk, que sí declara la cifra de parámetros, son la consecuencia de todo esto.

- DeepSeek

DeepSeek v4 se lanzó en 2026 (¿febrero-abril?) por el antes mencionado gran innovador empresario chino, como modelo de código abierto. No se sabe la cifra de parámetros (¿1 billón ÷ 1,6 billones? y “activos” 35 ÷ 49 mil millones).

Incorpora innovaciones, como el subsistema mHC (“manifold-constrained hyper-connections”, hiperconexiones con restricciones múltiples) para introducir estabilidad ⁽⁷⁾ y evitar descontroles y estallidos en los procesos de ajuste de parámetros que constituyen la esencia del entrenamiento.

Así mismo introduce “Engram” (memoria condicional) para mejorar la eficiencia de recuperación de datos de las memorias. Y compite con Gemini en cuanto a la información multimodal.

DeepSeek, que empezó trabajando con su parque de NVIDIA, ha pasado, en los tiempos duros del control estadounidense, a entrenar con “Ascend” de Huawei.

(7) Al introducir estabilidad en los procesos de ajuste de parámetros, como se ha indicado ya, se acorta enormemente el número de reiteraciones del entrenamiento, reduciéndose el proceso y abaratándolo enormemente (llegando a dividir su coste en la nube por 20).

II.5.- LA PRIMERA “AGENCIA”: LA ROBÓTICA

El nacimiento tecnológico de los robots es muy anterior al surgimiento de la revolución IT, para no añadir la IA al calendario.

Desde antes de la era moderna el reloj mecánico y las máquinas de entretenimiento de la aristocracia ya eran una anticipación.

En la posguerra de la segunda mundial hicieron su aparición los servomecanismos en los sistemas de frenado o las “cadenas transfert” en la mecanización de bloques de motor de explosión, o para la soldadura “por puntos” de carrocerías en líneas de montaje para la construcción automotor y otros muchos automatismos. El control numérico aplicado al funcionamiento de máquinas herramientas de mecanización de metales fue también un pertinente paso previo de la catarata de procedimientos “auto”.

Así se desarrollaron los robots avanzados, instalados en las industrias metalmetálicas y luego en todas las demás, antes de que se iniciara la revolución de la capacidad de cálculo maquinal y, a ella asociada, la de la IA.

Y ya bastante difundido el robot – la máquina capaz de sustituir al hombre en la realización de sus diferentes labores – tanto en las unidades de producción como en los hogares e infraestructuras públicas (con un parque actual de máquinas, con toda seguridad, superior al millón de unidades a escala mundial) apareció la rutilante capacidad de la IA, de intervenir a través de los modelos generativos en las labores diarias de la humanidad.

Y en esta fase de la historia del progreso técnico, ambos quehaceres hermanaron sus fines y sus medios.

En la actual revolución técnica de la IA, la vertiente de la “agencia” se convirtió en esencial y la “caja negra” protagonista del procesamiento de la información no se conformó con producir resultados de su mera inteligencia sino que pretendió además pasar “del pensamiento a la acción”, es decir a dar órdenes, a instruir, a iniciar y a controlar procesos materiales físicos. O sea salir del cerebro y entrar en el mundo (hasta ahora un privilegio del ser humano).

A la puerta de salida de la “caja” se encuentra ese resto del mundo y en el seno de éste ya viven y actúan nuevas criaturas muy desarrollados robots (sin piernas) y humanoides. Las dos fuerzas, máquinas que

necesitan IA e IA que necesita agentes, están destinadas y esto ya está ocurriendo, a la mutua combinación: la IA haciéndose con la robótica y los robots por su cuenta incorporando IA antes de que sea demasiado tarde.

Y, desde un punto de vista empresarial será lo que tenga que ser (quién absorba y metabolice a quién y quién sea metabolizado por quién).

Tabla 13

PANORAMA EMPRESARIAL Y GEOGRÁFICO DE LA ROBÓTICA (2026)

ROBÓTICA INDUSTRIAL CLÁSICA		
1.-	FANUC (Japón)	amplio espectro. 900.000 máquinas instaladas
2.-	ABB (Suiza)	para industria automotriz e industria pesada
3.-	YASKAWA / MOTOMAN (Japón)	servomotores
4.-	KUKA (Alemania) control (China)	aplicaciones industriales

ESPECIALISTAS INDUSTRIALES DE NICHOS		
1.-	EPSON ROBOTS (Japón)	ensamblaje electrónico de alta velocidad
2.-	STÄUBLI (Suiza)	precisión en salas “blancas” de semiconductores
3.-	KAWASAKI ROBOTICS (Japón)	
4.-	DENSO (Japón)	
5.-	UNIVERSAL ROBOTS (Dinamarca)	robots colaborativos
6.-	COMAU (Italia)	

HUMANOIDES (EE UU)		
1.-	TESLA	al principio para uso propio
2.-	FIGURE AI	en plantas de BMW
3.-	BOSTON DYNAMICS	robótica dinámica para plantas de Hyundai
4.-	AGILITY ROBOTICS	logística y almacenes
5.-	APPTRONIK	
6.-	1X TECHNOLOGIES	
7.-	SANCTUARY AI	doblaje de ropa

HUMANOIDES (China)		
1.-	UNITREE	humanoides muy económicos

2.-	AGI BOT / ZHIYUAN ROBOTICS	cuota 39% en mercado chino
3.-	UBTECH ROBOTICS	para educación, uso doméstico y atención al cliente

INFRAESTRUCTURAS Y PLATAFORMAS (EE UU)		
1.-	NVIDIA	uso general en los robots
2.-	AMAZON ROBOTICS	flota de más de 1 millón de robots
3.-	INTUITIVE SURGICAL	sistema daVinci

Fuente: Elaboración propia

Por estos motivos se incluye la Tabla 13, en la que se expone el panorama empresarial y geográfico de la robótica, donde se verifica que las fuerzas están concentradas en EE UU (aplicación de la IA), China (humanoides) y Japón y Suiza (robótica industrial, es decir trabajo maquinal esclavo).

Nótese la actual debilidad de la Unión Europea en la materia (ya que KUKA, de Alemania (robótica industrial, ha pasado a encontrarse bajo control accionarial chino).

El crecimiento de estas actividades puede medirse desde una práctica infinidad de vertientes, pero en cualquier caso consiste en doblar casi cada dos años (o entre dos y tres). Y esto no es más que el principio. Esta “extensión” de la capacidad humana, por llamarla así, está destinada, bajo la dirección y gobierno de la IA, a revolucionar tanto la paz como la guerra. Esto se está comprobando incesantemente.

II.6.- LA IA EN EL ESPACIO

Las iniciativas en el espacio están, de momento, bajo el manto operativo del empresario precursor E. Musk.

Su proyecto “Starlink”, está basado en miles de mini-satélites en órbita transmitiendo, a escala mundial, datos de acceso a internet a cualquier habitante localizado en las áreas de más remoto acceso del mundo. Y se encuentra ya en una fase muy madura de ejecución.

Musk añade ahora su segundo gran proyecto orbital – “Starmind” – destinado a crear, masivamente, capacidad de cálculo a nivel extra-terrestre, teniendo en mente la escasez, en la tierra, de los recursos necesarios para el funcionamiento de la IA: en general energía eléctrica continua y frío.

En el espacio, argumenta con lógica, se puede capturar la energía (de origen nuclear de fusión) que radia el Sol y aprovechar las bajas temperaturas que reinan en el espacio exterior para aportar frío.

Se trata de lanzar muchísimos satélites con capacidad IA y amplios paneles solares desplegados con una envergadura suficiente y una capacidad para consumir electricidad holgadas (en pico y en promedio). Así es el primer satélite de la serie, el AI1, que puede realizar inferencia IA en órbita y devolver resultados en milisegundos.

Desde luego para capitanear un proyecto así es necesario un espíritu pionero, una capacidad de toma de riesgo y una convicción de poder salvar obstáculos conocidos y desconocidos formidables. Si alguien hay en el mundo capaz de intentarlo ese es E. Musk.

El 8 de junio de 2026, tres días antes del fulgurante lanzamiento a bolsa de SpaceX, Elon Musk publicó un video en su “X”, en el que presentó las características de su “AI1”, el satélite de primera generación de la constelación satelital de IA de SpaceX, concepto para cuyo lanzamiento la Federal Trade Commission le ha autorizado ya un millón de satélites.

Algunas de sus características son las siguientes:

- Longitud de punta a punta: 70 m
- Altura, cuando está desplegado: 20 m
- Diseño: más fácil que el del Starlink (en funcionamiento)
- Sistemas solares, térmicos y de enlace laser: como los de Starlink
- Panel solar: de 150 KW (250 W/m²)

- Potencia de cómputo: 150 KW (en pico) y 120 KW (media)
- Densidad (declarada): 70 KW/Tm
- Peso (inferido): 2,1 Tm, aunque expertos externos apuntan a no menos de 6 Tm

Según Musk, la potencia de cálculo del satélite equivaldría a la de un “rack” de servidores NVIDIA GB300 (72 GPUs), en órbita.

Los modelos de “chips” serían, según SpaceX, para los GPUs “Rubin” de NVIDIA, y para CPUs los “Vera”.

El primer lanzamiento de ensayo se espera que tendrá lugar en 2027 y orbitará a entre 500 km y 2.000 km sobre la superficie terrestre. No ha habido declaraciones sobre el tamaño físico de la unidad de cálculo satelital.

Junto con estas informaciones sobre el satélite protagonista y sobre la ambición cuantitativa del concepto, Musk ha tenido que referirse a la producción física de esa gran cantidad de unidades y lo ha hecho, hablando de dos enormes unidades fabriles: “Gigasat” en Bastrop (Texas) y “Terafab”.

Además ha informado de que planea una industrialización muy integrada verticalmente, sobre todo en relación con la producción de “chips”. Esta voluntad plantea la gran cuestión tecnológica de la litografía.

En este sentido es público, por otra parte, que Musk está lanzando una apuesta tecnológica para circunvenir la necesidad de sistemas de litografía EUV que solamente produce ASML. Esta nueva tecnología alternativa, para poder imprimir a 2 nanómetros, es la del “laser de electrón libre” (FEL, “Free Electron Laser”), en la que viene trabajando xLight respaldada por el ex CEO de Intel, Pat Gelsinger. Una tecnología basada en la aceleración de partículas.

Es preciso indicar que las restricciones de equipamiento son duras, 100 fábricas requerirían 12.600 máquinas de litografía (ASML solo entregó 179 de ellas en 2025) y que Musk está mencionando 100.000 millones de “chips” desde el inicio y la producción inicial se ha fijado en 100.000 obleas por mes. Hipótesis todas ellas muy aventuradas.

Por otra parte el concepto FEL está en una fase muy inicial y convertirlo en un real instrumento industrial de impresión en masa tomará su tiempo, si ello se consigue.

Por este motivo la dependencia (en cualquier caso al principio del plan) respecto a ASML será inevitable y las capacidades de escalación de esta empresa holandesa tendrán su techo, el de la compleja realidad de cualquier magno-expansión industrial. Por lo que el gran proyecto de Musk queda limitado (en una proporción difícil de estimar pero, en cualquier caso, apreciable) desde su arranque, por el “cuello de botella” duro de la impresión litográfica de circuitos y su creciente miniaturización.

En ese sentido el “Proyecto Satelital IA” de Musk todavía no es propiamente un proyecto sino un designio, un propósito, un horizonte, que un hombre tan fuerte como él puede en efecto terminar llevando a la realidad.

Pero, hoy por hoy, todavía no es un proyecto (quizá esta sea una de las razones – no la única – de su comportamiento bursátil reciente poco después de su brillantísimo lanzamiento).

III.- COMENTARIO: RIESGO EXISTENCIAL FÍSICO

Leyendo para poder elaborar un documento sobre estos temas hay algo que ha sido lo que más me ha llamado la atención.

El examen de los proveedores de TSMC ha proyectado luz, independientemente de cualquier origen ajeno de la información utilizada para este documento, sobre los riesgos que para la actividad mundial – y sobre todo estadounidense – de la IA, implica la actual estructura de los suministros de todo tipo de maquinaria a esta empresa.

Parece evidente que el riesgo de un colapso general, principalmente (pero no únicamente) transmitido hacia el sector por cualquier problema en TSMC no se limita a esta empresa y sus instalaciones de producción en Taiwán.

Resulta que, a su vez TSMC tiene cinco proveedores de maquinaria críticos (de muy difícil sustitución en caso de que alguno de ellos pierda su capacidad de suministrar). No solamente ASML en Holanda (el proveedor clave) sino además tres industriales estadounidenses (Applied Materials, LA Research y KLA Corporation) y uno en Japón (Tokyo Electron).

Cualquier fallo de uno de ellos, cualquier parálisis seria de su capacidad de producir, generaría, a lo largo de la cadena, efectos, transmitidos al sistema IA estadounidense a través de incapacidades de operación principalmente por parte de NVIDIA.


El bloqueo de ésta (y otras) colapsaría la dotación de cualquier nuevo centro de datos en fase de creación o de proyecto en las nubes, poniendo a su vez en crisis a los grandes tecnogrupos y llevando al límite de los incumplimientos a su proceso de financiación-comercialización circular.

Esta potencialidad revela un grado de vulnerabilidad considerable, de naturaleza totalmente ajena al frecuentemente mencionado riesgo financiero de una potencial burbuja.

Este es un riesgo, en parte geopolítico y en parte existencial que, en general, no se comenta, pero que queda a la vista y claramente expuesto en este documento (ver la Tabla 14 adjunta que presenta los diez nodos críticos de esta vulnerabilidad).

Tabla 14

DISPOSICIÓN ORGÁNICA Y GEOGRÁFICA DE LA VULNERABILIDAD FÍSICA BÁSICA DE LA IA. 2026



COMENTARIO:

Colapsos de la producción de cualquiera de estas diez empresas (5 estadounidenses, cuatro asiáticas y una europea) podrían poner en seria dificultad (de grados diferentes cada una de ellas) el aumento de la capacidad de cálculo IA del mundo occidental. Los riesgos principales se concentran obviamente en ASML (Veldhoven) y en TSMC.

TSMC tiene 13 plantas en 3 localidades en Taiwán más dos en EE UU, dos en China y una en Japón, mientras que ASML concentra toda su potencia en las plantas de Veldhoven en las afueras de Eindhoven (sede clásica de Philips), planteando un riesgo sistémico especialmente pronunciado.



COMPLEJO TECNOLÓGICO INDUSTRIAL DE ASML EN VELDHOVEN

Obviamente la grandísima concentración de riesgo se produce en la gran planta de ASML en Veldhoven, vecina a Eindhoven (Holanda) (más de 250.000 m² construidos).

Estudiando la disposición de la maquinaria y las distribuciones en planta y tomando en consideración la duración del periodo necesario para reiniciar entregas de unidades de litografiado, se podría concebir una acción suficientemente incisiva para asestar un golpe durísimo a la ampliación y/o creación de capacidades de computación IA a escala mundial.

En total ignorancia de las medidas de seguridad puestas en pie actualmente en Veldhoven, puede resultar difícil de entender cómo el sector de actividad financieramente más poderoso del mundo (empezando por NVIDIA y terminando por los “hyperscalers”) puede permitirse mantener un flanco tan esencial y a la vez tan descubierto, en una era geopolítica y geoestratégicamente tan convulsa como la presente.

Si algo decisivo ocurriera quedaría inmediatamente cortado el suministro de piezas de repuesto, actualizaciones y (buena parte del) servicio de

asistencia técnica a todo el parque mundial de fundidores en Taiwán, China, Estados Unidos, Corea del Sur, etc...

No se podría entregar ninguna máquina EUV nueva, golpe fatídico contra TSMC, Samsung e Intel, cuyas actividades quedarían congeladas.

NVIDIA no podría lanzar nuevas generaciones de GPUs ni Google de TPUs. Los “hyperscalers” no podría ampliar su capacidad (quizá una bendición disfrazada, pero, de momento, traumática).

Es decir, un colapso del desarrollo de las actividades IA, que se quedarían, durante algún tiempo (probablemente varios años) con su capacidad de cálculo bloqueada.

¿Y el proyecto satelital “Starmind” de Musk? Pues quedaría pendiente de la maduración de su tecnología independiente de impresión FEL de mini-circuitos. No se trataría solo de Veldhoven ni de ASML sino de su red de 5.000 proveedores, que habría que re-constituir en su caso.

Puestos a hablar de concentración geográfica de riesgo de una industria, esta es máxima y afecta de manera determinante a la seguridad de la fuerza motriz número uno de la economía mundial.

ORIGEN DE LA INFORMACIÓN

A parte de los conocimientos del autor y en referencia a información adicional externa necesaria para su elaboración, este documento se ha realizado principalmente en base a datos obtenidos por medio del modelo “Claude” propietario de Anthropic y mediante el contraste, en determinados casos, mediante el modelo abierto chino “DeepSeek”.

Esto se refiere exclusivamente a información sobre las situaciones de hecho, pues las preguntas correspondientes han sido formuladas por el autor, así como las opiniones, comentarios y las conclusiones, que son exclusivamente suyas.